

評估報告與方法 (顧問 eval-designer 框架)

核心原則：量化指標只量「行為」不等於「正確」。每個數字都配一個質化檢查。
並且絕不引用訓練集準確率 (小資料會接近 100% 但毫無意義) 。

1. 偵測模型 — held-out 量化指標

測試集： `backend-api/model/testset.jsonl` (28 筆人工標註，與訓練資料不重疊，含 15 詐騙 / 13 正常) 。

執行： `cd backend-api && python -m model.evaluate`

指標	裸模型(TF-IDF+LogReg)	實際 ensemble(model+規則+RAG)	說明
準確率 Accuracy	96.4%	—	僅參考，類別不平衡下不可單看
詐騙偵出率 Recall	100%	100%	漏報=放走詐騙=真實傷害，最該高
正常誤報率 FPR	7.7%	15.4%	誤報=正常被當詐騙

誠實註記：

- 早期未平衡資料時 FPR 高達 69% (官方資料全為詐騙樣態→類別不平衡) 。補正常樣本後降到 7.7% 。這條改善過程本身就是專題的學習點。
- ensemble 多出的誤報是「本行**不會要求操作ATM**」這類含 ATM 字眼的反詐宣導被規則連坐 (eval-designer 預測的邊界案例 #14) 。屬可接受的保守誤判 (提醒使用者再看一眼) 。
- 樣本量小 (測試 28、訓練約 130) ，所有數字僅供專題參考，非生產級結論。

2. 偵測理由品質 — LLM-as-Judge 評分準則 (1–5)

量「reasoning 對該則訊息的針對性與正確性」。可請 Gemini/人工依此打分。

- 5 : verdict 正確；理由具體點出該訊息實際出現的詐騙訊號（引用命中的紅旗詞或相似案例類型），用一般民眾看得懂的話說明為何危險、該怎麼做；不誇大、不杜撰。
- 例：「出現『保證獲利30%』『加LINE進VIP群』屬假投資典型話術，且與歷史假投資案例相似，建議勿匯款並撥165。」
- 3 : verdict 正確或接近；理由合理但籠統（只說『含高風險詞，請保持警覺』而未說是哪句、為何），教育價值有限。
- 1 : verdict 錯誤，或理由與訊息矛盾 / 杜撰不存在的事實，或只回模板字句毫無針對性。

3. 「真 AI 含量」— engine 降級分布

每次 `/api/detect` 回傳 engine 欄位（`gemini+model+rule+rag` / `model+rule+rag` / `rule-fallback`）。

demo / 錄影前統計一批請求落在各 engine 的比例，誠實揭露目前有多少是真 AI（Gemini）參與、多少是模型/規則。無 Gemini key 時全為 `model+rule+rag`。

4. 模擬遊戲 — 教學效果（建議補做）

最小 quasi-experiment：同一份 5 題 pre-test → 玩遊戲 → 同格式 post-test，量分數差（learning gain）。找 3–5 位同學即可，作為「遊戲真的教會人」的證據。

5. End-to-End 20-trace 人工走查清單（demo/錄影前跑一遍）

丟 20–30 則訊息 + 玩一輪遊戲 + 看統計頁，逐項找問題：

1. 正常訊息被誤判詐騙（誤報，已知弱點，重點看銀行通知/家人訊息）。
2. 真實詐騙被判正常/uncertain（漏報，尤其新話術）。
3. reasoning 是否只是模板而非針對該則。
4. confidence 與對錯是否一致（高信心卻判錯）。
5. similar_examples 是否真的相似。
6. reasoning 是否杜撰訊息沒有的事實。
7. （Gemini 在線）同則重跑是否穩定。

7. 邊界輸入 (空字串/純網址/超長/英文/emoji) 是否崩潰。
8. engine 分布：實際多少比例是真 AI。
9. 統計頁數字是否對得起來源、示意值是否標示。
10. 遊戲答錯解說是否教會「為什麼錯+手法」。
11. 遊戲對錯判定是否正確。
12. 遊戲難度標示與實際相符。
13. 含連結的正常訊息是否被連坐誤判。
14. 繁簡混雜/非中文處理。
15. reasoning 語氣對焦慮受害者是否恰當。
16. 重複紅旗詞是否讓分數不合理飆高。
17. uncertain 區間是否給了可行動的下一步。
18. 詐騙類型涵蓋度 (假投資/網拍/交友/檢警/分期) 。
19. 整體：非技術使用者能否 30 秒看懂「是不是詐騙+為什麼+我該怎麼辦」。